

Reconocimiento de la Actividad Humana Basado en la Fusion de Datos con Python

Justificacion Cientifica y Metodologica del Pipeline sobre PAMAP2

Rabanales Andrade, Andry., Reyes Martinez, Miguel Angel., Monreal Nava, Agustin Antonio., Solis Ek, Emiliano., and Magana Mis, Marco Antonio.

Universidad Autonoma de Yucatan

2026

1 Proposito del Proyecto

El objetivo de este proyecto es el desarrollo de un **sistema de software para el Reconocimiento Automatico de la Actividad Humana (HAR)** mediante la fusion de datos de sensores inerciales y cardiovasculares wearables. El sistema identifica que actividad fisica realiza un individuo a partir de las senales capturadas por dispositivos portatiles, sin intervencion humana.

Las aplicaciones incluyen la monitorizacion de pacientes en rehabilitacion, el seguimiento de atletas, la deteccion de sedentarismo y el soporte a sistemas de atencion a personas mayores. El clasificador se entrena sobre los datos preprocesados del dataset PAMAP2 y debe generalizar a nuevos sujetos.

2 Dataset PAMAP2: Descripcion y Arquitectura

2.1 Caracteristicas generales

PAMAP2 *Physical Activity Monitoring* es un dataset multivariante de series temporales (Reiss & Stricker, 2012) con 3,850,505 instancias registradas. La cohorte comprende 9 sujetos sanos (1 mujer, 8 hombres), edad media 27.22 ± 3.31 anos. En estado crudo el DataFrame tiene 2,872,533 filas y 54 columnas.

Parametros tecnicos:

- **Frecuencia IMU:** 100 Hz | **Frec. cardiaca:** ≈ 9 Hz
- **Actividades doc.:** 18 | **Recuperables:** 12
- **IMUs:** muneca, pecho y tobillo del lado dominante

De las 18 actividades documentadas en el protocolo original, únicamente 12 fueron capturadas por el hardware utilizado en esta cohorte. Las 6 actividades ausentes (Sitting, Computer Work, Car Driving, Folding Laundry, House Cleaning y Playing Soccer) no generaron registros en ninguno de los 9 sujetos y quedan excluidas del análisis desde esta etapa. Una descripción detallada de la distribución de muestras por actividad recuperable se presenta

en la Sección 5.2.

2.2 Justificación de la arquitectura de sensado

IMU en muñeca. La mano posee mas de 25 grados de libertad, generando la mayor variabilidad cinematica del sistema durante ADL instrumentales (Wang & Wang, 2016).

IMU en pecho. Ancla gravitacional del sistema. Discrimina postura estatica (sentado, de pie, acostado) y filtra la cinematica de las extremidades.

IMU en tobillo. Estandar de oro biomecanico para metricas de deambulacion e impactos con el suelo durante Rope Jumping o Running.

Monitor cardiaco. Opera a ≈ 9 Hz frente a 100 Hz de las IMUs, factor $\approx 11\times$. Esta diferencia explica el 90.87% de NaN en heart_rate.

90.87% de NaN $\neq$ perdida de datos:

El sensor cardiaco genera una lectura real cada ≈ 11 filas del DataFrame. Son NaN generados directamente por diferencias entre las frecuencias de los sensores.

Modalidad	Ejes	Nota
Temperatura	1	24–38°C
Acelerometro $\pm 16g$	3	No se satura
Acelerometro $\pm 6g$	3	Mayor resolucion; se satura
Giroscopio	3	rad/s
Magnetometro	3	μT , alta variab. ambiental
Cuaterniones	4	Invalidos (eliminados)

3 Pipeline de Preprocesamiento

3.1 Diagnostico de NaN

Grupo	% NaN	Estrategia
Sensores IMU	< 0.5%	Interp. lineal, lim. 10
Heart rate	90.87%	Interp. lineal, lim. 100

3.2 Creacion de subject_id

Primera operacion absoluta del pipeline. Sin ella, ninguna interpolacion ni estadistica posterior puede respetar los limites entre sujetos:

```
df['subject_id'] = (df['timestamp'].diff() < 0).cumsum() + 1
```

Listing 1: Deteccion por reinicio de timestamp

3.3 Eliminacion de activityID = 0

Periodos transitorios entre actividades, sin etiqueta definida. Su inclusion contamina los patrones de clasificacion (Kyratzis, 2021). Reduce el dataset de 2,872,533 a 1,942,872 filas (32.4%).

3.4 Eliminacion de cuaterniones

Invalidos por deriva EKF:

Los Filtros de Kalman Extendidos del hardware acumulan deriva giroscopica severa en sesiones largas, por ausencia de recalibracion de interferencia magnetica (*hard/soft iron*). Los cuaterniones resultantes son vectores espaciales divergentes, invalidos segun la documentacion oficial de PAMAP2.

3.5 Analisis de saturacion y fusion jerarquica

3.5.1 Posicion en el pipeline

Este analisis **debe preceder a la interpolacion y al Z-Score** porque los limites fisicos de saturacion estan definidos en m/s^2 . Si se interpola primero, los valores saturados (falsos) se propagan a muestras vecinas. Si se estandariza primero, se pierde la referencia fisica.

3.5.2 Saturacion del $\pm 6g$

El sensor $\pm 6g$ ($\approx \pm 58.86 m/s^2$) ofrece mayor resolucion en movimientos sutiles pero recorta (*clipping*) los picos que exceden su rango. El resultado es un techo plano en el maximo del sensor: informacion falsa con apariencia de dato valido.

Umbrales de deteccion al 90% del limite:

$$U_{6g} = 52.97 m/s^2 \quad U_{16g} = 141.26 m/s^2 \quad (1)$$

Saturacion real: filas donde $|acc6| > U_{6g}$ y $|acc16| \leq U_{16g}$.

3.5.3 Por que conservar ambos sensores

Complementariedad $acc6$ / $acc16$:

El análisis de saturación confirmó que la tasa de saturación real del sensor $\pm 6g$ permaneció por debajo del umbral de decisión del 10% en todas las actividades y ubicaciones anatómicas (HAND: 0.22%, CHEST: 0.03%, ANKLE: 0.20%), por lo que no se realizó ningún reemplazo. Este resultado constituye un hallazgo empírico que valida la decisión de conservar ambos sensores con sus valores originales.

La complementariedad entre ambos acelerómetros responde a principios físicos bien documentados. El sensor de $\pm 6g$ ofrece mayor resolución en el rango de baja aceleración al distribuir sus bits de cuantificación sobre un rango menor, siendo superior para distinguir actividades sedentarias como Lying, Sitting y Standing (Frosio et al., 2013). El sensor de $\pm 16g$, por su parte, nunca alcanzó saturación en ninguna actividad del dataset y registró la magnitud real de los impactos durante actividades de alta intensidad como Rope Jumping y Running, donde las fuerzas de contacto con el suelo pueden superar los $100 m/s^2$ (Lafortune et al., 1996).

La decisión de conservar ambos sensores sin fusión jerárquica está además respaldada por la alta correlación observada entre $acc6$ y $acc16$ en el mismo eje ($r \approx 0.95-0.98$), documentada en el análisis de correlación intra-extremidad. Esta redundancia aparente es en realidad complementariedad específica del rango: en baja intensidad ambos sensores coinciden, mientras que en alta intensidad el $\pm 6g$ se satura y el $\pm 16g$ preserva la información real del impacto (Bao & Intille, 2004). Eliminar cualquiera de los dos implicaría sacrificar resolución en reposo o fidelidad en movimiento intenso, degradando la capacidad discriminativa del clasificador en ambos extremos del espectro de actividades.

3.6 Interpolacion lineal por sujeto

La interpolacion se aplica con `groupby('subject_id')` en todos los casos. Sin este agrupamiento, un NaN al inicio de la sesion del sujeto 102 podria imputarse con valores del final del sujeto 101, violando la independencia estadistica entre individuos.

La interpolacion lineal se justifica como polinomio interpolante de grado uno. Para gaps de

hasta 10 muestras (0.1 s a 100 Hz) el error es:

$$|E| \leq \frac{M_2}{8} (x_{n+1} - x_n)^2 \quad (M_2 = \max |f''(x)|) \quad (2)$$

Este metodo fue utilizado en el preprocesamiento original de PAMAP2 (Reiss & Stricker, 2012), validando directamente su uso.

```

# IMU: limit=10 muestras (0.1 s a 100 Hz)
df[imu_cols] = df.groupby('subject_id')[imu_cols].transform(
    lambda x: x.interpolate(method='linear', limit=10))

# Heart rate: limit=100 (~1 s a la frecuencia cardiaca)
df['heart_rate'] = df.groupby('subject_id')['heart_rate'].transform(
    lambda x: x.interpolate(method='linear', limit=100))

# Extremos residuales por sujeto
for col in imu_cols + ['heart_rate']:
    df[col] = df.groupby('subject_id')[col].transform(
        lambda x: x.ffill().bfill())

```

Listing 2: Interpolacion con independencia de sujeto

4 Verificacion de Coherencia del Heart Rate

4.1 Limite fisiologico teorico

Para adultos jovenes de 27.22 ± 3.31 anos, el maximo teorico de frecuencia cardiaca se calcula como (Tanaka et al., 2001):

$$HR_{\max} = 208 - 0.7 \times \text{edad} \approx 208 - 0.7 \times 27 = 189 \text{ BPM} \quad (3)$$

Se adopta un limite de seguridad de 200 BPM para absorber la variabilidad de la cohorte (± 3.31 anos). El minimo fisiologico se fija en 40 BPM (umbral clinico de bradicardia severa).

4.2 Procedimiento de verificacion

Al explorar la matriz de dispersion de atributos se observaron valores elevados de frecuencia cardiaca en ciertas actividades. Para determinar si eran artefactos de la interpolacion o datos reales del sensor, se procedio a:

1. Contabilizar filas con $HR < 40$ o $HR > 200$ BPM por actividad y sujeto.
2. Clasificar los atipicos segun la intensidad de la actividad en que ocurrian.
3. Examinar la serie temporal completa de cada sujeto para detectar transiciones abruptas inconsistentes con el inicio/final de sesion.
4. Comparar el perfil de atipicos con el patron esperado de ruido de un sensor cardiaco comercial bajo movimiento intenso.

4.3 Resultados del diagnostico

Resultado del analisis de atipicos:

- Atipicos en actividades de **ALTA** intensidad: **0.23%**
- Atipicos en actividades de **BAJA** intensidad: **0.00%**
- Actividad mas afectada: Rope Jumping (1.72% de sus filas)




Figure 1: Verificación de coherencia del HR. Distribución global, boxplot por sujeto, HR medio por actividad (orden de intensidad respetado) y serie temporal de extremos de sesión. Ningun sujeto presenta transiciones abruptas en los extremos que indiquen artefactos de imputación.

4.4 Interpretación: ruido del sensor, no artefacto de imputación

La ausencia total de atípicos en actividades de baja intensidad descarta que la interpolación o el `ffill/bfill` sean la causa: un artefacto de imputación propagaría valores extremos hacia todos los frames adyacentes, independientemente de la actividad.

Los valores superiores a 189 BPM durante Rope Jumping son fisiológicamente plausibles en adultos jóvenes. Durante actividad física maximal, la frecuencia cardíaca puede alcanzar o superar el límite teórico calculado por la fórmula de Tanaka en un porcentaje de individuos (Robergs & Landwehr, 2002). Además, los monitores cardíacos comerciales de banda pectoral son susceptibles al *motion artifact*: la contracción muscular intensa durante el salto produce señales eléctricas que el sensor puede interpretar erróneamente como latidos, generando lecturas espurias de alta frecuencia (Brage et al., 2005).

Decision: clip de seguridad, no eliminación:

Dado que los atípicos se concentran exclusivamente en actividades de alta intensidad y representan menos del 0.23% del total, se aplica un clip de seguridad [40, 200] BPM como única medida preventiva. Se conservan las observaciones: eliminarlas implicaría descartar momentos de esfuerzo máximo, que son precisamente los más discriminativos para el clasificador.

Si la frecuencia cardíaca se incluye como feature en el modelado, se deberá evaluar su impacto mediante ablación (entrenamiento con y sin ella) dada la tasa de error del sensor comercial bajo alta intensidad.

5 Análisis Exploratorio de Datos

5.1 Tipos de dato y resumen estadístico

Todos los atributos son `float64` (excepto `activityID`, `int64`), consistente con Reiss & Stricker (2012). La segmentación del resumen estadístico por ubicación anatómica evita mezclar escalas incompatibles ($^{\circ}\text{C}$, m/s^2 , μT).

5.2 Distribución de clases

El dataset contiene 12 actividades validas tras excluir activityID=0. Las 6 ausentes (Sitting, Computer Work, Car Driving, Folding Laundry, House Cleaning, Playing Soccer) no fueron capturadas

por el hardware.

Actividad	Muestras	%
Lying	192,616	9.91
Sitting	185,280	9.53
Standing	190,066	9.78
Walking	238,896	12.29
Running	98,163	5.05
Cycling	164,607	8.47
Nordic Walking	188,222	9.68
Ascending Stairs	117,145	6.03
Descending St.	104,979	5.40
Vacuum Cleaning	175,517	9.03
Ironing	238,896	12.29
Rope Jumping	49,385	2.54
Total	1,942,872	100

Japkowicz & Stephen (2002) consideran critico un desbalance cuando la clase minoritaria cae por debajo del 1%. Rope Jumping (2.54%) supera ese umbral; no se requiere sobremuestreo obligatorio.




Figure 2: Distribucion de las 12 actividades validas. Barras: conteo de muestras. Pastel: proporcion relativa. Walking e Ironing dominan; Rope Jumping es la clase minoritaria con 2.54%.

5.3 Histogramas: fenomenologia distribucional




Figure 3: Histogramas de frecuencia cardiaca, temperatura y acelerómetros/giroscopios de la muñeca. Se observa el pico prominente en cero (estados estacionarios) y la multimodalidad que evidencia la mezcla de regimenes de actividad.

Seleccion de la muñeca como referencia. La mano es el sensor de mayor varianza cinematica: 25+ grados de libertad producen distribuciones mas informativas para detectar anomalias que el pecho o el tobillo (Wang & Wang, 2016).

Pico en cero y multimodalidad. El pico prominente centrado en cero en aceleracion y velocidad angular representa estados estacionarios (Lying, Sitting) que dominan en duracion. Las distribuciones fuertemente multimodales confirman que el dataset es una mezcla de procesos estocasticos distintos, cada modo correspondiendo a un regimen de actividad. Esto **justifica fronteras de decision no lineales** en el clasificador.

Rangos dinamicos dispares. Temperatura en rango decimal estrecho vs. acelerómetros a 155 m/s² vs. magnetómetros en centenas de μ T confirman empiricamente la necesidad de estandarizacion.

5.4 Boxplots: Outliers como Eventos Biomecanicos Legitimos

5.4.1 Que es el IQR y como se aplica en deteccion de outliers

El Rango Intercuartilico (*Interquartile Range*, IQR) es una medida robusta de dispersion estadistica definida como la diferencia entre el tercer y el primer cuartil de una distribucion:

$$IQR = Q_3 - Q_1 \quad (4)$$

El criterio convencional de Tukey (1977) establece que cualquier valor fuera del intervalo $[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR]$ se considera un candidato a valor atipico. La ventaja del IQR sobre la desviacion estandar como medida de dispersion es su robustez: al basarse en los cuartiles centrales ignora los propios extremos que pretende detectar, lo que lo hace resistente a la distorsion por valores anormales (Rousseeuw & Croux, 1993).

En ciencia de datos general, los valores fuera de $1.5 \times IQR$ se interpretan como errores de medicion, datos corruptos o eventos excepcionales no representativos de la poblacion estudiada. Esta

interpretacion es correcta en dominios donde las distribuciones son aproximadamente gaussianas y donde un valor extremo indica efectivamente una anomalia del proceso de medicion.

5.4.2 Por que esta interpretacion falla en HAR

El Reconocimiento de Actividad Humana opera sobre una premisa opuesta: las distribuciones de aceleracion, velocidad angular y fuerza de impacto son **inherentemente no gaussianas y multimodales** (Bao & Intille, 2004). Cada actividad genera un regimen cinematico propio, y la superposicion de regimenes produce distribuciones con colas largas estructuradas, no por ruido sino por la fisica del movimiento.

En PAMAP2, los valores de aceleracion superiores a $1.5 \times \text{IQR}$ corresponden casi exclusivamente a tres fenomenos fisicos bien caracterizados:

- *Impacto de contacto con el suelo* durante Rope Jumping y Running: la desaceleracion brusca al aterrizar genera picos de $\approx 100\text{--}155 \text{ m/s}^2$ en el acelerometro del tobillo, perfectamente medibles por el sensor $\pm 16g$ y fisicamente esperados para un adulto de $\approx 70 \text{ kg}$ saltando desde $\approx 30 \text{ cm}$ de altura (Lafortune et al., 1996).
- *Aceleracion maxima en Ascending Stairs*: el impulso del pie contra el escalon genera picos superiores en el eje vertical del tobillo que en la marcha llana, diferenciando ambas actividades por su firma de impacto (Janidarmian et al., 2017).
- *Movimientos bruscos de muñeca* durante Vacuum Cleaning e Ironing: los cambios de direccion rapidos del brazo producen picos en los acelerómetros de la muñeca que quedan fuera del IQR calculado sobre el conjunto completo de actividades.

Eliminar estos valores por el criterio de Tukey equivaldria a eliminar los momentos de mayor intensidad cinematica de cada actividad — precisamente aquellos que el clasificador necesita para separar clases de alta intensidad de las sedentarias (Sant’Anna & Wickstrom, 2010).

5.4.3 El IQR como herramienta de auditoria, no de limpieza

Aunque el IQR no debe usarse para eliminar datos en HAR, si es util como herramienta de auditoria del pipeline. Comparar el rango intercuartilico antes y despues de la interpolacion permite verificar que la imputacion no altero la distribucion central de los datos. Un IQR identico entre el dataset crudo (post-eliminacion de $\text{activityID}=0$) y el dataset interpolado es evidencia de que la interpolacion lineal solo relleno gaps internos sin modificar la estructura estadistica de la senal.

Regla practica para HAR. Antes de aplicar cualquier criterio de eliminacion de outliers sobre senales biomecanicas, verificar en que actividades ocurren los valores extremos. Si los valores fuera de $1.5 \times \text{IQR}$ se concentran en actividades de alta intensidad (Running, Rope Jumping, Ascending Stairs), son eventos fisicos legitimos y deben conservarse. Si aparecen en actividades de baja intensidad (Lying, Sitting), son candidatos a artefactos de medicion o de imputacion y requieren inspeccion individual (Bao & Intille, 2004; Janidarmian et al., 2017). En PAMAP2, el analisis de confiabilidad del heart rate realizado en la Sec. 4 aplico exactamente este criterio: los valores atipicos de BPM ocurrieron exclusivamente en alta intensidad (0.23%) y ninguno en baja intensidad (0.00%), confirmando que son ruido del sensor cardiaco comercial bajo movimiento intenso, no artefactos de imputacion.




Figure 4: Boxplot de acelerómetros $\pm 16g$ (mano, pecho, tobillo). Los bigotes representan $1.5 \times \text{IQR}$; los puntos exteriores son candidatos estadísticos a outliers. Estos valores extremos corresponden a impactos físicos reales durante Rope Jumping y Running, no a ruido estadístico. Eliminarlos destruiría la información más discriminativa del dataset.

5.4.4 Estrategia de visualización: agrupación por tipo de sensor

La Figura 4 agrupa los boxplots por tipo de sensor ($\pm 16g$ únicamente) en lugar de mezclar todas las modalidades en un único gráfico. Esta decisión responde a la disparidad de escalas documentada en el análisis de histogramas: la frecuencia cardíaca oscila en el rango 40–200 BPM; el giroscopio del pecho en $[-7.5, 7.5]$ rad/s; el acelerómetro en $[-155, 155]$ m/s². Representar las tres modalidades en el mismo eje Y colapsaría las distribuciones de menor escala a una línea horizontal indistinguible, perdiendo la información sobre su varianza intrínseca (Wilkinson & Friendly, 2009).

Al segmentar por tipo de sensor, cada panel puede escalar de forma independiente y revelar la estructura real de la distribución: mediana cercana a cero para todos los sensores (reflejo del predominio de actividades estáticas y de baja intensidad en duración), con bigotes asimétricos que muestran la mayor amplitud de los picos de alta aceleración respecto a los valles, coherente con la naturaleza impulsiva de los impactos de contacto.

5.5 KDE por actividad: separabilidad de clases




Figure 5: Distribucion de densidad (KDE) de frecuencia cardíaca por actividad. Lying y Running muestran separacion clara (alto poder discriminativo). Standing e Ironing se solapan casi completamente, demostrando que un sensor unico es insuficiente: se requiere fusion multi-sensor.

Atributo	Act. A	Act. B	Separab.
Frec. cardíaca	Lying	Running	Alta
Aceler. mano	Standing	Ironing	Baja
Giroscop. tobillo	Walking	Running	Moderada

El solapamiento entre Standing e Ironing justifica empíricamente la fusión de datos multi-sensor (Zhang et al., 2024): ningún sensor único puede resolver esta ambigüedad.

5.6 Matrices de correlacion: necesidad de todos los sensores

Se generan tres tipos de matrices para cubrir distintos niveles de analisis.

5.6.1 Correlacion intra-extremidad




Figure 6: Matrices de correlacion intra-extremidad (mano, pecho, tobillo). La alta correlacion acc6/acc16 ($r \approx 0.95-0.98$) evidencia redundancia resuelta por fusion jerarquica. Giroscopios y magnetometros presentan baja correlacion entre si, confirmando que miden dimensiones ortogonales del movimiento.

La alta correlacion entre acc16 y acc6 ($r \approx 0.95-0.98$) en el mismo eje no implica que sean sustituibles: el analisis de saturacion muestra que la redundancia es aparente y especifica del rango de baja intensidad. En alta intensidad cada uno captura informacion unica.

5.6.2 Correlacion inter-extremidad




Figure 7: Matriz de correlacion cruzada entre atributos representativos de las tres ubicaciones anatomicas. La baja correlacion confirma que muñeca, pecho y tobillo capturan dimensiones del movimiento irreemplazables entre si.

Los tres sensores son necesarios:

La baja correlacion inter-extremidad demuestra empiricamente que cada ubicacion anatomica captura una dimension del movimiento que las otras no pueden suplir: la muñeca registra la cinematica de manipulacion de objetos; el pecho la postura global del tronco; el tobillo los patrones de deambulacion e impactos. Si dos ubicaciones estuvieran altamente correlacionadas, una podria eliminarse sin perdida de informacion. La evidencia muestra que no es el caso.

5.7 Matriz de Dispersion Multivariada

La Figura 8 presenta la matriz de dispersion entre cuatro atributos representativos: frecuencia cardiaca (heart_rate), aceleracion vertical de la muñeca (hand_acc16_1), velocidad angular del

pecho (chest_gyr1) y campo magnetico del tobillo (ankle_mag1), cada punto coloreado por actividad. Esta visualizacion condensa en una sola figura la separabilidad de clases, las correlaciones cruzadas entre modalidades y la presencia de actividades de alta intensidad como valores extremos; es la sintesis grafica del analisis exploratorio completo.




Figure 8: Matriz de dispersion multivariada (muestra estratificada, 500 obs./actividad). Diagonal: densidades KDE por actividad. Off-diagonal: nubes de puntos coloreadas por activityID. Los clusters verdes dispersos (Running, ID=5) y naranjas (Cycling, ID=6) revelan las actividades de mayor varianza cinematica.

5.7.1 Lectura fisica de la figura

Tres patrones son inmediatamente visibles y tienen interpretacion fisica directa.

Separabilidad en heart_rate (columna izquierda). Las distribuciones de densidad en la diagonal muestran que la frecuencia cardiaca separa bien las actividades: Lying y Sitting forman un pico estrecho en la zona de reposo ($\approx 60-80$ BPM), mientras que Running y Rope Jumping tienen distribuciones desplazadas hacia $140-190$ BPM. Esta separacion confirma cuantitativamente lo observado en el analisis KDE: el ritmo cardiaco es el discriminador de intensidad mas poderoso del

dataset.

Concentracion en chest_gyr1 (tercera columna/fila). El giroscopio del pecho presenta una distribucion extremadamente concentrada en cero para casi todas las actividades. Esto refleja su funcion fisiologica: el tronco es el ancla gravitacional del sistema y rota poco en la mayoria de las ADL. Su valor discriminativo surge no de la media sino de momentos de mayor orden: varianza y picos maximos diferencian efectivamente las transiciones posturales.

Alta varianza en ankle_mag1 (columna/fila derecha). El magnetometro del tobillo presenta la mayor dispersion, sin patron de agrupamiento claro por actividad. Esto es consistente con la alta susceptibilidad del magnetometro a interferencias ambientales (Frosio et al., 2013): el campo magnetico local varia segun la posicion del sujeto y la proximidad a objetos ferromagneticos. Su utilidad discriminativa es baja en datos instantaneos pero puede recuperarse en caracteristicas de ventana, donde la entropia espectral captura la irregularidad del patron de movimiento.

5.7.2 Por que el muestreo estratificado es fundamental

Para construir esta figura se aplico un submuestreo estratificado de 500 observaciones por actividad en lugar de muestreo aleatorio simple sobre el dataset completo (≈ 1.9 millones de filas). Esta decision no es estetica sino metodologica.

Efecto del muestreo sobre la evaluacion de separabilidad. Con muestreo aleatorio simple, la probabilidad de seleccionar una observacion es proporcional a la frecuencia de su clase. Walking e Ironing (12.29% cada una) tendrian ≈ 4.8 veces mas puntos que Rope Jumping (2.54%). El resultado visual es una nube densa que ocultaria la estructura de las clases minoritarias: el investigador concluiria erroneamente que Rope Jumping no forma un cluster distinguible. El muestreo estratificado garantiza que todas las clases tengan el mismo peso visual, haciendo la evaluacion de separabilidad equitativa.

Formalmente, si n_i es el tamano de la clase i y N el total, la probabilidad bajo muestreo aleatorio simple es $P_i = n_i/N$. Con muestreo estratificado de k unidades por clase:

$$P(\text{obs. de clase } i) = \frac{k}{n_i} \quad \forall i \quad (5)$$

En la figura se puede observar que incluso Rope Jumping (clase minoritaria) forma nubes de puntos discernibles en los paneles heart_rate vs. hand_acc16_1.

6 Estandarizacion Z-Score

6.1 Falla estructural de Min-Max

La normalizacion Min-Max transforma cada valor al rango $[0, 1]$ usando los extremos globales:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (6)$$

Con picos de $\pm 155 \text{ m/s}^2$ durante Rope Jumping, esos extremos actuan como anclas del 0 y del 1. La inmensa mayoria de los movimientos cotidianos ocurre en el rango $[-10, 10] \text{ m/s}^2$, de modo que Min-Max comprime el 95% de la varianza util en un margen minusculo (≈ 0.5), destruyendo la resolucion para distinguir actividades de intensidad similar como Walking y Ascending Stairs.

6.2 Superioridad del Z-Score

La estandarización Z-Score centra la media en cero y escala por la desviación estándar:

$$z = \frac{x - \mu}{\sigma} \quad (7)$$

Los picos de alta intensidad quedan a varias σ del centro sin distorsionar el rango del resto del dataset. Este comportamiento es preferible para K-NN y SVM con kernel RBF, donde las distancias euclidianas deben ser comparables entre atributos, y para redes neuronales profundas, donde evita la saturación de gradientes en la retropropagación (Patro & Sahu, 2015).

El Z-Score resuelve además la disparidad de escala entre modalidades (m/s² vs. μ T vs. rad/s vs. °C) sin factores de conversión manuales que alterarían la física de las señales. Esta homogenización es también la razón por la cual el análisis de saturación de acelerómetros (Sec. 3.4) debe realizarse **antes** del Z-Score: una vez estandarizado, los límites físicos de ± 58.86 m/s² ya no son detectables en el espacio transformado.

Se excluyen explícitamente timestamp (referencia temporal, no feature), activityID (etiqueta de clase cuya transformación alteraría la semántica de las etiquetas) y subject_id (identificador auxiliar creado durante el pipeline cuya estandarización carecería de interpretación física, pudiendo introducir ruido numérico en etapas posteriores) (Géron, 2022).

6.3 Optimización

Previo a la extracción de características, se aplicó una reducción de precisión numérica convirtiendo las columnas de sensores de float64 a float32. Esta operación se realizó deliberadamente después de completar el preprocesamiento y la estandarización Z-Score, garantizando que ninguna operación aritmética sensible a la precisión decimal se viera comprometida.

La justificación técnica radica en que float64 ofrece aproximadamente 15 dígitos de precisión decimal, mientras que float32 ofrece 7 dígitos (IEEE 754, 2008). Dado que los valores estandarizados Z-Score se distribuyen típicamente en el rango $[-4, 4]$ con variaciones en el cuarto o quinto decimal significativo, float32 es suficiente para representar fielmente la información sin pérdida práctica de resolución numérica.

Esta técnica, conocida como *mixed precision*, es ampliamente utilizada en proyectos de *machine learning* a gran escala para reducir el consumo de memoria RAM hasta un 50% sin impacto en la calidad del modelo (Micikevicius et al., 2018). En el contexto de PAMAP2, con aproximadamente 1.94 millones de filas y 40 columnas de sensores, la conversión redujo el espacio en memoria de 652.21 MB a 322.40 MB, representando un ahorro real del 50.6% (329.81 MB), facilitando operaciones de extracción de características y entrenamiento del modelo en entornos con recursos computacionales limitados.

Adicionalmente, las columnas activityID y subject_id fueron convertidas a int8, dado que sus valores están acotados en rangos pequeños (1–24 y 1–9 respectivamente), eliminando el sobredimensionamiento implícito de int64.

7. Extracción de Características

7.1 De Datos Crudos a Características: Justificación Física

7.1.1 El problema de los datos instantáneos

Cada fila del DataFrame representa una medición en un instante de 0.01 segundos (100 Hz). Un clasificador que opera sobre filas individuales enfrenta dos problemas físicos fundamentales.

Ambigüedad temporal. El vector de aceleración en un instante aislado no permite distinguir si el sujeto está en la fase de ascenso de un salto o en la de aterrizaje, aunque ambos instantes pertenezcan a Rope Jumping. El patrón de actividad se manifiesta en la evolución temporal de la señal, no en muestras aisladas (Bulling et al., 2014).

Ruido de alta frecuencia. Los sensores MEMS a 100 Hz capturan vibraciones mecánicas, ruido eléctrico y artefactos de contacto sin correlato con la actividad realizada. La agregación temporal sobre una ventana actúa como filtro paso-bajo implícito, reduciendo el ruido intra-ciclo y preservando la estructura del patrón de actividad (Banos et al., 2014).

7.1.2 La ventana como unidad de análisis

La solución estándar en HAR es segmentar la serie en ventanas de duración fija y extraer características estadísticas de cada segmento (Bulling et al., 2014). Siguiendo la metodología propuesta por Garcia-Ceja et al. (2018), se adoptaron ventanas de 3 segundos sin traslape (300 muestras a 100 Hz), valor respaldado por Banos et al. (2014) quienes en una evaluación extensiva de diferentes longitudes de ventana demostraron que 3 segundos es el valor estándar para sistemas de reconocimiento de actividad con sensores inerciales, siendo suficiente para capturar al menos un ciclo completo de las actividades periódicas del dataset.

7.1.3 Diferencia analítica entre dato crudo y característica

La reducción de ~1.94 millones a ~6,396 vectores (factor $\approx 300\times$) no implica pérdida de información relevante: elimina el ruido intra-ciclo y preserva la estructura del patrón de actividad en representaciones compactas y computacionalmente manejables para los algoritmos de clasificación (Bulling et al., 2014).

7.1.4 Características extraídas según Garcia-Ceja et al. (2018)

Siguiendo las 16 características definidas por Garcia-Ceja et al. (2018) para sensores triaxiales, se calcularon por cada ventana de 3 segundos las siguientes métricas estadísticas temporales:

Para cada sensor de 3 ejes (acelerómetro $\pm 16g$, acelerómetro $\pm 6g$, giroscopio y magnetómetro en mano, pecho y tobillo):

- **Media por eje (X, Y, Z):** refleja la orientación promedio del sensor respecto a la gravedad, discriminando actividades estáticas de dinámicas (3 features).
- **Desviación estándar por eje (X, Y, Z):** representa la amplitud típica de oscilaciones, alta en movimientos repetitivos y baja en reposo (3 features).
- **Valor máximo absoluto por eje (X, Y, Z):** captura los picos de aceleración durante impactos de alta intensidad como Rope Jumping y Running (3 features).
- **Correlación entre pares de ejes (XY, XZ, YZ):** describe el acoplamiento entre ejes durante movimientos coordinados (3 features).
- **Magnitud media:** norma euclidiana promedio del vector tridimensional, equivalente a la potencia media de la señal (1 feature).
- **Desviación estándar de la magnitud:** variabilidad de la intensidad del movimiento (1 feature).
- **Área bajo la curva de la magnitud (AUC):** integral discreta de la magnitud, proporcional al impulso total del movimiento en la ventana (1 feature).
- **Diferencias medias entre muestras consecutivas de magnitud:** mide la tasa de cambio del movimiento, alta en actividades con cambios abruptos de dirección (1 feature).

Para sensores de un eje (temperatura y frecuencia cardíaca) se extrajeron 4 características: media, desviación estándar, valor máximo absoluto y área bajo la curva.

Tabla X. Características estadísticas extraídas por ventana de 3 s — García-Ceja et al. (2016)

#	Característica	Descripción física	Sensores aplicables	Features por sensor
Sensores triaxiales — 16 características por sensor				
1	Media eje X	Orientación promedio respecto a la gravedad	Acc±16g, Acc±6g, Gyr, Mag	1
2	Media eje Y	Orientación promedio respecto a la gravedad	Acc±16g, Acc±6g, Gyr, Mag	1
3	Media eje Z	Orientación promedio respecto a la gravedad	Acc±16g, Acc±6g, Gyr, Mag	1
4	Desv. estándar eje X	Amplitud típica de oscilación por eje	Acc±16g, Acc±6g, Gyr, Mag	1
5	Desv. estándar eje Y	Amplitud típica de oscilación por eje	Acc±16g, Acc±6g, Gyr, Mag	1
6	Desv. estándar eje Z	Amplitud típica de oscilación por eje	Acc±16g, Acc±6g, Gyr, Mag	1
7	Máximo absoluto eje X	Picos de impacto en actividades de alta intensidad	Acc±16g, Acc±6g, Gyr, Mag	1
8	Máximo absoluto eje Y	Picos de impacto en actividades de alta intensidad	Acc±16g, Acc±6g, Gyr, Mag	1
9	Máximo absoluto eje Z	Picos de impacto en actividades de alta intensidad	Acc±16g, Acc±6g, Gyr, Mag	1
10	Correlación XY	Acoplamiento entre ejes en movimiento coordinado	Acc±16g, Acc±6g, Gyr, Mag	1
11	Correlación XZ	Acoplamiento entre ejes en movimiento coordinado	Acc±16g, Acc±6g, Gyr, Mag	1
12	Correlación YZ	Acoplamiento entre ejes en movimiento coordinado	Acc±16g, Acc±6g, Gyr, Mag	1
13	Magnitud media	Potencia media de la señal tridimensional	Acc±16g, Acc±6g, Gyr, Mag	1
14	Desv. estándar de magnitud	Variabilidad de la intensidad del movimiento	Acc±16g, Acc±6g, Gyr, Mag	1
15	AUC de magnitud	Impulso total del movimiento en la ventana	Acc±16g, Acc±6g, Gyr, Mag	1
16	Diferencias medias de magnitud	Tasa de cambio del movimiento entre muestras consecutivas	Acc±16g, Acc±6g, Gyr, Mag	1
Sensores uniaxiales — 4 características por sensor				
—	Media	Valor promedio en la ventana	Temperatura, Heart Rate	1
—	Desv. estándar	Variabilidad en la ventana	Temperatura, Heart Rate	1
—	Máximo absoluto	Valor pico en la ventana	Temperatura, Heart Rate	1
—	AUC	Integral discreta en la ventana	Temperatura, Heart Rate	1

Tabla Y. Conteo total de características extraídas (208 features)

Ubicación	Sensores triaxiales	Features (×16)	Sensores uniaxiales	Features (×4)	Subtotal
Mano	Acc±16g, Acc±6g, Gyr, Mag	64	Temperatura	4	68
Pecho	Acc±16g, Acc±6g, Gyr, Mag	64	Temperatura	4	68
Tobillo	Acc±16g, Acc±6g, Gyr, Mag	64	Temperatura	4	68
Global	—	—	Heart Rate	4	4
Total		192		16	208

7.2 Ventanas Deslizantes sin Traslape: Implementación

Se adoptan ventanas de 3 segundos sin traslape:

$$N_{\text{ventana}} = f_s \times t = 100 \times 3 = 300 \text{ muestras}$$

7.2.1 Independencia entre sujetos en la segmentación

La asignación del identificador de ventana se realizó de forma independiente para cada sujeto mediante `groupby('subject_id')`, garantizando que ninguna ventana mezcle datos de dos sujetos distintos. Sin este agrupamiento, la segmentación global con `np.arange` produciría ventanas fronterizas que combinarían los últimos frames del sujeto N con los primeros frames del sujeto N+1, violando la independencia estadística entre individuos y contaminando las características extraídas (Chavarriaga et al., 2013). Esta corrección es especialmente crítica para la evaluación Leave-One-Subject-Out (LOSO), donde la separación entre sujetos debe ser estricta.

7.2.2 Filtro de pureza de ventanas

Adicionalmente al etiquetado por moda, se aplicó un filtro de pureza mínima del 90%, eliminando ventanas donde la actividad predominante no superó dicho umbral. Este filtro reduce el ruido de etiquetado en ventanas de transición entre actividades, que de conservarse introducirían vectores de características ambiguos en el conjunto de entrenamiento, degradando potencialmente el rendimiento del clasificador (Bulling et al., 2014). Como resultado, se eliminaron 85 ventanas de las 6,481 totales, obteniendo 6,396 vectores finales.

7.2.3 Preservación del identificador de sujeto

El identificador `subject_id` fue incluido en el DataFrame de características `df_features` como columna auxiliar no utilizada como feature de entrenamiento. Su preservación es indispensable para implementar correctamente la validación cruzada Leave-One-Subject-Out (LOSO), donde en cada iteración un sujeto completo actúa como conjunto de prueba y los ocho restantes como conjunto de entrenamiento. Esta estrategia de evaluación es el estándar en HAR porque mide la

capacidad del modelo para generalizar a sujetos no vistos durante el entrenamiento (Chavarriaga et al., 2013).

7.3 Resultado de la Extracción

La extracción produjo un dataset de **6,396 vectores de características**, reduciendo los ~1.94 millones de filas crudas en un factor de aproximadamente 300×. Cada vector contiene la etiqueta de actividad, el identificador de sujeto y las características estadísticas calculadas sobre cada sensor, siguiendo estrictamente las 16 características definidas por Garcia-Ceja et al. (2018). Esta representación compacta preserva la estructura del patrón de actividad mientras reduce drásticamente el costo computacional del entrenamiento del modelo.

8 Tabla Resumen de Decisiones

Decision	Rechazada	Fundamento
subject_id primero	Sin ID	Impide operaciones por sujeto
Eliminar ID=0	Conservar	Contamina clasificacion
Eliminar cuaterniones	Conservar	Deriva EKF invalida
Saturacion pre-interp.	Post Z-Score	Requiere escala m/s^2
Conservar acc6+acc16	Eliminar uno	Se complementan por rango
Fusion directa	Factor 0.375	Mismas unidades fisicas
Interp. por sujeto	Global	Evita contaminacion inter-suj.
Clip HR [40,200]	Eliminar atip.	Ruido sensor, no artefacto
Conservar outliers	Elim. por IQR	Eventos fisicos legitimos
3 matrices correlacion	Matriz 42x42	Relaciones fisiologicas
Corr. inter-extrem.	Solo intra	Justifica 3 sensores
Z-Score	Min-Max	Robusto ante picos altos
Muestreo estratíf.	Aleatorio	Representacion equitativa
Ventana 3 s sin trasl.	Con traslape	Baseline limpio
Media + Std como feat.	Solo FFT	Baseline rapido (Bulling, 2014)

9. Clasificación

9.1 División de datos

El conjunto de características (df_features) se compone de vectores derivados de ventanas temporales de 3 segundos, cada uno representado mediante un conjunto compacto de características estadísticas diseñadas para capturar la dinámica del movimiento.

A diferencia de un esquema tradicional de partición aleatoria o división fija por sujetos, en este trabajo se empleó una validación Leave-One-Subject-Out (LOSO), en la cual cada iteración utiliza un sujeto completo como conjunto de prueba y los ocho restantes como conjunto de entrenamiento, rotando los 9 sujetos disponibles. Esta estrategia garantiza que ninguna ventana del sujeto evaluado aparezca durante el entrenamiento, eliminando el data leakage inter-sujeto y produciendo una estimación del desempeño promediada sobre todos los individuos del dataset (Chavarriaga et al., 2013).

Este enfoque es el estándar metodológico en HAR, ya que evita que el modelo aprenda patrones específicos de los individuos y refleja de forma realista la capacidad de generalización ante sujetos no vistos previamente (Bulling et al., 2014). En cada pliegue, la estandarización Z-score se ajustó exclusivamente sobre los datos de entrenamiento y se aplicó al conjunto de prueba, garantizando la ausencia de data leakage en la normalización (Géron, 2022). Del mismo modo, las transformaciones de reducción de dimensionalidad y selección de características se ajustaron dentro de cada fold.


9.2 Clasificadores evaluados

Se evaluaron tres clasificadores de acuerdo con los requerimientos del proyecto:

Regresión Logística: modelo lineal que estima probabilidades mediante una función sigmoide multinomial. Su limitación radica en asumir separabilidad lineal entre clases (Bishop, 2006).

Perceptrón: clasificador lineal basado en actualizaciones iterativas de pesos en función del error. Al igual que la regresión logística, presenta limitaciones para modelar relaciones no lineales complejas (Rosenblatt, 1958).

Random Forest: método de ensemble basado en árboles de decisión, que permite modelar relaciones no lineales y capturar interacciones entre variables mediante múltiples particiones del espacio de características (Breiman, 2001).



9.3 Justificación del mejor clasificador

Los resultados obtenidos bajo evaluación LOSO muestran que el mejor desempeño se alcanza con Random Forest en combinación con selección de características, con una exactitud promedio de $89.43\% \pm 4.66\%$, la menor varianza entre pliegues de toda la evaluación. Este resultado es especialmente significativo porque se obtiene promediando sobre los 9 sujetos del dataset, sin dependencia de una partición específica favorable.

El mejor desempeño de Random Forest puede explicarse por su capacidad para capturar relaciones no lineales y complejas entre las características. La variabilidad inter-sujeto introduce patrones que no son completamente separables de manera lineal, condición que favorece a los clasificadores no lineales en escenarios de generalización real (Lara & Labrador, 2013). La Regresión Logística ($84.49\% \pm 9.03\%$) y el Perceptrón ($85.31\% \pm 7.56\%$), si bien competitivos bajo selección de características, presentaron mayor varianza entre pliegues, indicando mayor sensibilidad a las características particulares del sujeto de prueba.

En contraste, técnicas como PCA y Kernel PCA no mejoraron el desempeño. PCA maximiza la varianza global sin considerar la relevancia discriminativa, pudiendo eliminar componentes informativos para la clasificación (Bishop, 2006). Kernel PCA produjo el desempeño más bajo e inestable, especialmente en Regresión Logística ($69.67\% \pm 27.17\%$), con la mayor desviación

estándar del experimento, evidenciando su inadecuación para este problema bajo evaluación LOSO.

9.4 Análisis de la matriz de confusión

Con el propósito de analizar en mayor profundidad el desempeño del modelo seleccionado, se presenta la matriz de confusión agregada correspondiente a Random Forest con selección de características (89.43% LOSO), construida acumulando las predicciones de los 9 pliegues.


De manera general, se observa una alta concentración de valores en la diagonal principal, indicando que la mayoría de las instancias fueron clasificadas correctamente en todos los sujetos evaluados. Al analizar por tipo de actividad se identifican tres patrones principales.

Las actividades dinámicas (Walking, Running, Cycling, Nordic Walking, Rope Jumping) presentan los mayores niveles de precisión y recall, con F1-scores superiores a 0.90 en la mayoría de los casos. Estas actividades generan señales con mayor variabilidad, amplitud y periodicidad, lo que facilita su discriminación entre sujetos (Bulling et al., 2014).

Las actividades estáticas o cuasi-estáticas (Sitting, Standing, Lying) muestran confusiones moderadas entre sí, con F1-scores entre 0.79 y 0.91. Estas clases presentan distribuciones similares en el espacio de características, lo que dificulta su separación ante la variabilidad inter-sujeto (Roggen et al., 2013).

Las actividades intermedias (Ascending Stairs, Descending Stairs, Vacuum Cleaning) presentan cierto grado de solapamiento debido a la combinación de componentes dinámicos y patrones parcialmente similares, con F1-scores entre 0.84 y 0.88.

En conjunto, la matriz de confusión muestra un desempeño alto y balanceado, con errores estructurados que reflejan la naturaleza del problema más que deficiencias del modelo.



9.5 Análisis del impacto de la reducción de características

Los resultados LOSO confirman que la reducción de dimensionalidad tiene un impacto variable según el método utilizado. La selección de características mejoró el desempeño de los tres clasificadores: Random Forest pasó de $89.34\% \pm 5.71\%$ a $89.43\% \pm 4.66\%$, con una reducción adicional de la varianza entre pliegues que refleja mayor estabilidad ante la variabilidad inter-sujeto. La Regresión Logística y el Perceptrón mostraron mejoras más pronunciadas, de 81.82% a 84.49% y de 82.04% a 85.31% respectivamente.

PCA degradó el desempeño de Random Forest de forma notable (de 89.34% a 74.93%), con una desviación estándar de $\pm 24.26\%$, la mayor inestabilidad registrada en todo el experimento. Esto confirma que PCA, al priorizar la varianza global sin considerar la relevancia discriminativa, destruye información crítica para Random Forest que opera directamente sobre las variables originales (Bishop, 2006; Breiman, 2001).

Kernel PCA produjo el peor desempeño global, con Regresión Logística cayendo a $69.67\% \pm 27.17\%$. La alta varianza inter-pliegue indica que la proyección no lineal con 20 componentes es insuficiente

para capturar la estructura multimodal del PAMAP2 ante sujetos completamente nuevos (Reiss & Stricker, 2012).

En consecuencia, la combinación de un modelo no lineal con selección de características constituye la estrategia más efectiva y estable para este problema.

9.6 Resultados

Los resultados experimentales obtenidos bajo evaluación LOSO (9 folds, 1 sujeto por fold) se presentan en la siguiente tabla:

Clasificador	Sin reducción	PCA	Kernel PCA	Selección
Regresión Logística	81.82% $\pm$ 12.55%	80.86% $\pm$ 13.28%	69.67% $\pm$ 27.17%	84.49% $\pm$ 9.03%
Random Forest	89.34% $\pm$ 5.71%	74.93% $\pm$ 24.26%	78.70% $\pm$ 12.62%	89.43% $\pm$ 4.66%
Perceptrón	82.04% $\pm$ 12.16%	78.99% $\pm$ 10.99%	73.62% $\pm$ 18.68%	85.31% $\pm$ 7.56%

El mejor desempeño fue obtenido por Random Forest con selección de características (89.43% $\pm$ 4.66%), seguido de Random Forest sin reducción (89.34% $\pm$ 5.71%). Estos resultados permiten extraer cuatro conclusiones principales.

Primera conclusión: Random Forest es el clasificador más adecuado para este problema. En tres de los cuatro escenarios evaluados, Random Forest supera a la Regresión Logística y al Perceptrón. Su capacidad para modelar relaciones no lineales entre las 208 características extraídas, su robustez ante la variabilidad inter-sujeto y su mecanismo de votación por ensemble lo hacen especialmente adecuado para HAR con sensores inerciales (Breiman, 2001; Bulling et al., 2014).

Segunda conclusión: La selección de características mejora la estabilidad de Random Forest. La reducción de 208 a 124 características mediante SelectKBest (f_classif) produjo una mejora de 89.34% a 89.43% en accuracy, pero más relevante aún, redujo la varianza entre pliegues de $\pm 5.71\%$ a $\pm 4.66\%$, indicando mayor consistencia ante diferentes sujetos. La selección identifica las variables con mayor poder discriminativo respecto a la variable objetivo, reduciendo el ruido y mejorando la generalización (Géron, 2022; Guyon & Elisseeff, 2003).

Tercera conclusión: PCA degrada severamente el desempeño de Random Forest bajo LOSO. La aplicación de PCA produjo una caída de 89.34% a 74.93% con una desviación estándar de $\pm 24.26\%$, evidenciando que la proyección lineal destruye la estructura de particiones que Random Forest explota en el espacio original y amplifica la variabilidad inter-sujeto al eliminar componentes discriminativos (Bishop, 2006; Breiman, 2001).

Cuarta conclusión: Kernel PCA es la técnica más perjudicial del experimento. La transformación no lineal con 20 componentes RBF produjo el peor desempeño global (Regresión Logística: 69.67% $\pm$ 27.17%), con la mayor inestabilidad entre pliegues de todo el experimento. Bajo LOSO, donde cada sujeto es completamente nuevo para el modelo, la proyección en un espacio de baja dimensionalidad no lineal resulta insuficiente para capturar la variabilidad inter-sujeto inherente al PAMAP2 (Reiss & Stricker, 2012; Schölkopf et al., 1998).

En conjunto, estos resultados confirman que la combinación óptima para el reconocimiento de actividad humana con el dataset PAMAP2 bajo evaluación LOSO es Random Forest con selección de características ($89.43\% \pm 4.66\%$), estrategia que maximiza tanto el rendimiento como la estabilidad ante sujetos no vistos durante el entrenamiento.

10. Validación Cruzada

Los resultados numéricos coinciden con la sección 9 porque ambos usan LOSO, pero aquí el análisis se centra en las métricas de calidad del modelo (precision, recall, F1) en lugar del impacto de la reducción dimensional

Con el propósito de estimar la capacidad de generalización de los modelos de manera robusta y libre de sesgo inter-sujeto, se aplicó una validación cruzada Leave-One-Subject-Out (LOSO) sobre el conjunto completo de vectores de características extraídos del dataset PAMAP2. En cada iteración, un sujeto completo actúa como conjunto de prueba y los ocho restantes como conjunto de entrenamiento, rotando los 9 sujetos disponibles. Esta estrategia garantiza que ninguna ventana del sujeto evaluado aparezca durante el entrenamiento, eliminando el data leakage inter-sujeto que introduciría una validación cruzada por instancias (Chavarriaga et al., 2013). Las métricas reportadas —accuracy, precision, recall y F1-score ponderados— se expresan como media $\pm$ desviación estándar sobre los nueve pliegues, siguiendo la práctica estándar en HAR (García-Ceja et al., 2018).

10.1 Resultados por estrategia de representación

Sin reducción de dimensionalidad (208 características). Random Forest obtuvo el mayor accuracy promedio (0.8934 ± 0.0571) y el F1 más alto (0.8954 ± 0.0694), con la menor varianza entre pliegues de los tres clasificadores en esta configuración, confirmando su estabilidad como método de conjunto (Breiman, 2001). La Regresión Logística (0.8182 ± 0.1255) y el Perceptrón (0.8204 ± 0.1216) mostraron desempeño similar entre sí pero con desviaciones estándar notablemente mayores, indicando mayor sensibilidad a la composición específica del sujeto de prueba en cada pliegue.

PCA (reducción al 95% de varianza explicada). La proyección lineal produjo caídas de desempeño en los tres modelos respecto a la configuración sin reducción. Random Forest descendió a 0.7493 ± 0.2426 , registrando la mayor inestabilidad de esta configuración — una desviación estándar de ± 0.2426 indica que el rendimiento varía drásticamente según el sujeto de prueba. La Regresión Logística (0.8079 ± 0.1329) y el Perceptrón (0.7825 ± 0.1117) mostraron mayor estabilidad relativa. Este comportamiento confirma que PCA, al maximizar la varianza global sin considerar la relevancia discriminativa, puede eliminar componentes informativos para la clasificación (Jolliffe, 2002), efecto que se amplifica bajo LOSO donde la variabilidad inter-sujeto queda completamente expuesta.

Kernel PCA (20 componentes, kernel RBF). Esta configuración produjo el desempeño más bajo e inestable del experimento. La Regresión Logística alcanzó únicamente 0.6967 ± 0.2717 , la desviación estándar más elevada de toda la evaluación, evidenciando que la proyección no lineal con 20 componentes es insuficiente para capturar la estructura multimodal de las señales del PAMAP2

ante sujetos no vistos (Reiss & Stricker, 2012). Random Forest fue nuevamente el más robusto en esta configuración (0.7876 ± 0.1264), aunque con rendimiento inferior a las demás estrategias.

Selección de características (SelectKBest, 124 de 208 features). Esta configuración produjo los mejores resultados globales del experimento. Random Forest alcanzó el mayor accuracy (0.8943 ± 0.0466) y F1 (0.8984 ± 0.0556), con la menor varianza entre pliegues de toda la evaluación LOSO, lo que refleja la mayor estabilidad ante la variabilidad inter-sujeto. La Regresión Logística obtuvo 0.8449 ± 0.0903 y el Perceptrón 0.8531 ± 0.0756 , ambos con mejoras respecto a las demás configuraciones. La eliminación del 40% de características menos discriminativas redujo el ruido de entrada y estabilizó el rendimiento de los tres clasificadores (Guyon & Elisseeff, 2003; García-Ceja et al., 2018).

10.2 Síntesis comparativa

Los resultados LOSO confirman que **Random Forest con selección de características** es la configuración óptima ($F1 = 0.8984 \pm 0.0556$), resultado consistente con la evaluación de clasificación LOSO (89.43%), donde el mismo modelo también fue superior. Las desviaciones estándar elevadas observadas en algunas configuraciones (especialmente Kernel PCA: ± 0.2717 en Regresión Logística, y PCA: ± 0.2426 en Random Forest) son inherentes a LOSO con 9 sujetos y reflejan la variabilidad real entre individuos, no inestabilidad del modelo (Arlot & Celisse, 2010).

```
=====
RESULTADOS VALIDACIÓN CRUZADA – LOSO (9 folds, 1 sujeto/fold)
=====
```

Dataset	Clasificador	Accuracy	Precision	Recall	F1-Score
Sin Reducción	Regresión Logística	0.8182 ± 0.1255	0.8555 ± 0.1320	0.8182 ± 0.1255	0.8067 ± 0.1576
Sin Reducción	Random Forest	0.8934 ± 0.0571	0.9229 ± 0.0469	0.8934 ± 0.0571	0.8954 ± 0.0694
Sin Reducción	Perceptrón	0.8204 ± 0.1216	0.8350 ± 0.1517	0.8204 ± 0.1216	0.8107 ± 0.1510
PCA	Regresión Logística	0.8079 ± 0.1329	0.8421 ± 0.1344	0.8079 ± 0.1329	0.8051 ± 0.1503
PCA	Random Forest	0.7493 ± 0.2426	0.8750 ± 0.0717	0.7493 ± 0.2426	0.7474 ± 0.2207
PCA	Perceptrón	0.7825 ± 0.1117	0.8469 ± 0.1031	0.7825 ± 0.1117	0.7822 ± 0.1257
Kernel PCA	Regresión Logística	0.6967 ± 0.2717	0.7139 ± 0.2748	0.6967 ± 0.2717	0.6879 ± 0.2752
Kernel PCA	Random Forest	0.7876 ± 0.1264	0.8439 ± 0.1046	0.7876 ± 0.1264	0.7825 ± 0.1525
Kernel PCA	Perceptrón	0.7363 ± 0.1868	0.7787 ± 0.1500	0.7363 ± 0.1868	0.7224 ± 0.1969
Selección	Regresión Logística	0.8449 ± 0.0903	0.8827 ± 0.1009	0.8449 ± 0.0903	0.8485 ± 0.0969
Selección	Random Forest	0.8943 ± 0.0466	0.9200 ± 0.0481	0.8943 ± 0.0466	0.8984 ± 0.0556
Selección	Perceptrón	0.8531 ± 0.0756	0.8859 ± 0.0955	0.8531 ± 0.0756	0.8571 ± 0.0907

10.3 Consistencia entre Clasificación y Validación Cruzada LOSO

Los resultados de ambas evaluaciones LOSO son coherentes y se refuerzan mutuamente. Tanto en clasificación como en validación cruzada, **Random Forest con selección de características** emerge como el modelo superior, con *accuracy* de 89.43% en ambos experimentos. Esta coincidencia prácticamente exacta valida la robustez del modelo ante la variabilidad inter-sujeto del PAMAP2 y confirma que los resultados no dependen de una partición específica favorable, sino que reflejan una capacidad de generalización real y consistente (Chavarriaga et al., 2013; Bulling et al., 2014).

10.4 Punto de Equilibrio Óptimo (Sweet Spot)

La selección de características actúa como mecanismo regulador del equilibrio entre sesgo y varianza (bias-variance tradeoff), principio fundamental en el diseño de modelos de aprendizaje automático (Geman et al., 1992). Los resultados LOSO ilustran este fenómeno con claridad: el Perceptrón, modelo de alta simplicidad, mostró alta varianza entre pliegues en espacios de alta dimensionalidad; Random Forest, modelo complejo, exhibió la menor varianza bajo selección de características gracias a su mecanismo de agregación (Breiman, 2001); la Regresión Logística, de complejidad moderada, mostró consistencia intermedia en todas las configuraciones.

La selección de 124 de las 208 características mediante SelectKBest operó como regularizador implícito: redujo el ruido de entrada, eliminó redundancia y estabilizó el rendimiento de los tres clasificadores. Bajo LOSO, este efecto es especialmente visible en la reducción de la desviación estándar de Random Forest, que pasó de ± 0.0571 sin reducción a ± 0.0466 con selección. La combinación Random Forest + Selección de características representa el punto de equilibrio óptimo del experimento: un modelo con capacidad no lineal suficiente para capturar la variabilidad inter-sujeto, operando sobre un espacio de características depurado que maximiza la generalización (Domingos, 1999; James et al., 2013).

11. Fusión de Datos y sus Métodos

Se evaluaron tres métodos de fusión de modelos —Agregación con Bosques Aleatorios (Bagging), Votación con diferentes clasificadores (Regresión Logística, Random Forest y Naive Bayes) y AdaBoost— mediante validación cruzada *Leave-One-Subject-Out* (LOSO) sobre las tres configuraciones de representación del PAMAP2. Los métodos de fusión buscan reducir el error de generalización combinando las predicciones de múltiples modelos base, aprovechando la diversidad entre ellos para compensar las debilidades individuales (Dietterich, 2000).

Agregación con Bosques Aleatorios (Bagging) obtuvo el mayor *accuracy* promedio en las configuraciones Sin Reducción (0.9019 ± 0.0482) y Selección (0.8956 ± 0.0480), con la menor varianza entre pliegues de los tres métodos en ambas configuraciones. Este comportamiento es consistente con la naturaleza del Bagging, que reduce la varianza del estimador base mediante el promedio de múltiples modelos entrenados sobre submuestras aleatorias del conjunto de entrenamiento (Breiman, 1996). Bajo LOSO, donde cada sujeto es completamente nuevo para el modelo, la estabilidad del Bagging resulta especialmente valiosa. Sin embargo, bajo PCA descendió a 0.7629 ± 0.2314 , la mayor inestabilidad registrada en esta configuración, confirmando que la proyección lineal amplifica la variabilidad inter-sujeto en modelos de conjunto.

Votación con múltiples clasificadores presentó un desempeño competitivo y consistente en las tres configuraciones, destacando especialmente bajo PCA (0.8506 ± 0.1003), donde superó ampliamente al Bagging. La combinación de clasificadores heterogéneos —lineal (Regresión Logística), no lineal (Random Forest) y probabilístico (Naive Bayes)— mediante votación suave (*soft voting*) permite integrar perspectivas complementarias del espacio de características, lo que favorece la generalización en espacios transformados bajo LOSO (Kuncheva, 2004). Su varianza entre pliegues fue consistentemente moderada en todas las configuraciones (< 0.120), indicando robustez ante la variabilidad inter-sujeto.

AdaBoost mostró el desempeño más bajo e inestable de los tres métodos, con *accuracy* promedio entre 0.4928 y 0.5435 y desviaciones estándar elevadas (hasta ± 0.2068). Bajo LOSO, este resultado es especialmente pronunciado respecto a evaluaciones con StratifiedKFold, ya que la exposición completa a sujetos no vistos amplifica la sensibilidad de AdaBoost al ruido: al asignar pesos

crecientes a las instancias mal clasificadas, el algoritmo sobrepondera ejemplos atípicos o ambiguos propios de la variabilidad inter-sujeto del PAMAP2, degradando severamente la generalización (Freund & Schapire, 1997). Adicionalmente, AdaBoost fue diseñado originalmente para clasificación binaria y su extensión multiclase mediante SAMME introduce limitaciones adicionales en problemas de 12 clases (Hastie et al., 2009).

En términos globales, **Agregación RF (Bagging) sin reducción** fue el mejor método de fusión ($F1 = 0.9061 \pm 0.0559$), superando ligeramente al clasificador individual óptimo identificado en las etapas anteriores (Random Forest + Selección, $F1 = 0.8984 \pm 0.0556$). Este resultado sugiere que, bajo evaluación LOSO, la capa adicional de agregación exterior sobre Random Forest aporta una mejora marginal de generalización ante sujetos no vistos. Sin embargo, la diferencia es inferior al 1%, por lo que ambas configuraciones son prácticamente equivalentes en términos prácticos, y la selección entre ellas debe considerar el costo computacional adicional del Bagging (Dietterich, 2000).

=====					
RESULTADOS MÉTODOS DE FUSIÓN – LOSO (9 folds, 1 sujeto/fold)					
=====					
Dataset	Método Fusión	Accuracy		Precision	
Sin Reducción	Agregación RF (Bagging)	0.9019 ± 0.0482	0.9282 ± 0.0421	0.9019 ± 0.0482	0.9061 ± 0.0559
Sin Reducción	Votación (LR + RF + NB)	0.8676 ± 0.0703	0.8902 ± 0.0864	0.8676 ± 0.0703	0.8676 ± 0.0864
Sin Reducción	AdaBoost	0.4928 ± 0.2068	0.5188 ± 0.2287	0.4928 ± 0.2068	0.4602 ± 0.2039
PCA	Agregación RF (Bagging)	0.7629 ± 0.2314	0.8783 ± 0.0708	0.7629 ± 0.2314	0.7646 ± 0.2019
PCA	Votación (LR + RF + NB)	0.8506 ± 0.1003	0.8708 ± 0.1165	0.8506 ± 0.1003	0.8493 ± 0.1188
PCA	AdaBoost	0.5435 ± 0.2038	0.6058 ± 0.2230	0.5435 ± 0.2038	0.5305 ± 0.2027
Selección	Agregación RF (Bagging)	0.8956 ± 0.0480	0.9232 ± 0.0439	0.8956 ± 0.0480	0.9003 ± 0.0552
Selección	Votación (LR + RF + NB)	0.8632 ± 0.0721	0.8793 ± 0.0857	0.8632 ± 0.0721	0.8590 ± 0.0924
Selección	AdaBoost	0.5282 ± 0.1389	0.6621 ± 0.1457	0.5282 ± 0.1389	0.5142 ± 0.1261

Cabe señalar que la configuración Kernel PCA fue excluida de la evaluación de métodos de fusión. Esta decisión se fundamenta en los resultados LOSO de clasificadores individuales, donde Kernel PCA produjo el desempeño más bajo e inestable de todas las configuraciones: el Perceptrón alcanzó únicamente 0.7363 ± 0.1868 de *accuracy*, la mayor desviación estándar registrada en ese experimento. Dado que los métodos de fusión construyen sus predicciones sobre la representación del espacio de entrada, una proyección que degrada sistemáticamente el desempeño de los clasificadores base no constituye un punto de partida adecuado para la combinación de modelos (Kuncheva, 2004). Por tanto, la evaluación se restringió a las tres configuraciones con mayor estabilidad y desempeño demostrado: Sin Reducción, PCA y Selección de características (Dietterich, 2000).

11.1 Síntesis y Recomendación de Implementación

Los resultados de la evaluación de métodos de fusión bajo validación LOSO confirman que la agregación mediante Bagging sobre Random Forest sin reducción de dimensionalidad constituye la configuración de mayor desempeño global ($F1 = 0.9061 \pm 0.0559$), superando marginalmente al clasificador individual óptimo identificado en etapas anteriores (Random Forest + Selección, $F1 = 0.8984 \pm 0.0556$). Sin embargo, dado que la diferencia es inferior al 1%, ambas configuraciones son prácticamente equivalentes en términos de capacidad discriminativa.

La elección entre ambas debe considerar el contexto de despliegue del sistema HAR. En entornos con recursos computacionales limitados, como dispositivos wearables embebidos o aplicaciones móviles de monitorización en tiempo real, Random Forest con selección de características

representa la opción preferible: ofrece un rendimiento prácticamente idéntico con un costo computacional significativamente menor, ya que opera sobre 124 características en lugar de un ensemble de bosques sobre las 208 originales. En entornos con capacidad de cómputo suficiente, como servidores de análisis clínico o plataformas de seguimiento deportivo en la nube, el Bagging sobre Random Forest aporta la mayor estabilidad ante sujetos no vistos, lo que es especialmente relevante cuando la cohorte de usuarios es heterogénea.

En cuanto a AdaBoost, los resultados confirman su inadecuación estructural para este problema: su sensibilidad al ruido inter-sujeto bajo LOSO y las limitaciones de su extensión multiclase mediante SAMME lo descartan como alternativa viable para sistemas HAR con más de dos clases de actividad y evaluación sobre sujetos no vistos.

En conjunto, el pipeline desarrollado sobre PAMAP2 demuestra que es posible alcanzar tasas de reconocimiento superiores al 89% generalizando a sujetos completamente nuevos, utilizando exclusivamente sensores inerciales y cardiovasculares wearables de bajo costo, sin intervención humana en el proceso de clasificación. Este resultado valida la viabilidad del sistema propuesto para aplicaciones reales de monitorización de pacientes en rehabilitación, seguimiento de atletas y detección de sedentarismo, objetivos establecidos en la sección 1 de este documento.

Referencias

- Arlot, S., & Celisse, A. (2010). A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4, 40–79.
- Banos, O., Galvez, J. M., Damas, M., Pomares, H., & Rojas, I. (2014). Window size impact in human activity recognition. *Sensors*, 14(4), 6474–6499. <https://doi.org/10.3390/s140406474>
- Bao, L., & Intille, S. S. (2004). Activity recognition from user-annotated acceleration data. *Lecture Notes in Computer Science*, 3001, 1–17. https://doi.org/10.1007/978-3-540-24646-6_1
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.
- Brage, S., Brage, N., Franks, P. W., Ekelund, U., & Wareham, N. J. (2005). Reliability and validity of the combined heart rate and movement sensor Actiheart. *European Journal of Clinical Nutrition*, 59(4), 561–570.
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Bulling, A., Blanke, U., & Schiele, B. (2014). A tutorial on human activity recognition using body-worn inertial sensors. *ACM Computing Surveys*, 46(3), 1–33.
- Burden, R. L., & Faires, J. D. (2010). *Numerical analysis* (10th ed.). Cengage Learning.
- Chavarriaga, R., Sagha, H., Calatroni, A., Digumarti, S. T., Tröster, G., Millán, J. R., & Roggen, D. (2013). The Opportunity challenge: A benchmark database for on-body sensor-based activity recognition. *Pattern Recognition Letters*, 34(15), 1950–1958. <https://doi.org/10.1016/j.patrec.2013.01.014>

- Dietterich, T. G. (2000). Ensemble methods in machine learning. *Lecture Notes in Computer Science*, 1857, 1–15.
- Domingos, P. (1999). The role of Occam's razor in knowledge discovery. *Data Mining and Knowledge Discovery*, 3(4), 409–425.
- Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and application to boosting. *Journal of Computer and System Sciences*, 55(1), 119–139.
- Frosio, I., Pedersini, F., & Borghese, N. A. (2013). Autocalibration of triaxial MEMS accelerometers with automatic sensor model selection. *IEEE Transactions on Instrumentation and Measurement*, 62(3), 557–567.
- García-Ceja, E., Galván-Tejada, C. E., & Brena, R. (2018). Multi-view stacking for activity recognition with sound and accelerometer data. *Information Fusion*, 40, 45–56.
- Geman, S., Bienenstock, E., & Doursat, R. (1992). Neural networks and the bias/variance dilemma. *Neural Computation*, 4(1), 1–58.
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2nd ed.). Springer.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning*. Springer.
- Janidarmian, M., Roshan Fekr, A., Radecka, K., & Zilic, Z. (2017). A comprehensive analysis on wearable acceleration sensors in human activity recognition. *Sensors*, 17(3), 529.
- Japkowicz, N., & Stephen, S. (2002). The class imbalance problem: A systematic study. *Intelligent Data Analysis*, 6(5), 429–449.
- Jolliffe, I. T. (2002). *Principal component analysis* (2nd ed.). Springer.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, 2, 1137–1143.
- Kuncheva, L. I. (2004). *Combining pattern classifiers: Methods and algorithms*. Wiley.
- Kyratzis, D. (2021). *HAR using wearable sensor data* [Software]. GitHub. <https://github.com/dkyratzis/HAR-PAMAP2>
- Lafortune, M. A., Cavanagh, P. R., Sommer, H. J., & Kalenak, A. (1996). Foot mechanical energy and running economy. *Journal of Biomechanics*, 29(11), 1477–1483.
- Lara, O. D., & Labrador, M. A. (2013). A survey on human activity recognition using wearable sensors. *IEEE Communications Surveys & Tutorials*, 15(3), 1192–1209.
- Mickevičius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., Ginsburg, B., Houston, M., Kuchaiev, O., Venkatesh, G., & Wu, H. (2018). Mixed precision training. *Proceedings of the 6th International Conference on Learning Representations (ICLR)*.
- Nakamura, K., & Morrison, S. F. (2008). A thermosensory pathway that controls body temperature. *Nature Neuroscience*, 11(1), 62–71.
- Noor, N. M., Al Bakri Abdullah, M. M., Yahaya, A. S., & Ramli, N. A. (2014). Comparison of linear interpolation method and mean method to replace the missing values in environmental data set. *Materials Science Forum*, 803, 278–281.

- Patro, S., & Sahu, K. K. (2015). Normalization: A preprocessing stage. *International Journal of Advanced Research in Computer Science and Software Engineering*, 5(3), 20–22.
- Reiss, A., & Stricker, D. (2012). Introducing a new benchmarked dataset for activity monitoring. *Proceedings of the 16th IEEE International Symposium on Wearable Computers (ISWC)*, 108–109.
- Robergs, R. A., & Landwehr, R. (2002). The surprising history of the "HRmax = 220 – age" equation. *Journal of Exercise Physiology Online*, 5(2), 1–10.
- Roggen, D., Calatroni, A., Rossi, M., Holleczech, T., Förster, K., Tröster, G., Lukowicz, P., Bannach, D., Pirkel, G., Ferscha, A., Doppler, J., Feldmann, C., Fortsmann, C., Beetz, M., Wipophan, C., & Kasteren, T. V. (2010). Collecting complex activity datasets in highly rich networked sensor environments. *Proceedings of the 7th International Conference on Networked Sensing Systems (INSS)*, 233–240.
- Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
- Rousseeuw, P. J., & Croux, C. (1993). Alternatives to the median absolute deviation. *Journal of the American Statistical Association*, 88(424), 1273–1283.
- Sant'Anna, A., & Wickström, N. (2010). Introducing the attribute outlier detection in human gait analysis. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*.
- Schölkopf, B., Smola, A., & Müller, K. R. (1998). Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5), 1299–1319.
- Stolk, D. A., Cnossen, F., & Bhatt, P. (2023). Missing data imputation for wireless vital signs monitoring in step-down units. *Journal of Clinical Monitoring and Computing*, 37, 1487–1496.
- Tanaka, H., Monahan, K. D., & Seals, D. R. (2001). Age-predicted maximal heart rate revisited. *Journal of the American College of Cardiology*, 37(1), 153–156.
- Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.
- Wang, J., & Wang, K. (2016). Biomechanical characteristics of hand coordination in grasping activities of daily living. *PLOS ONE*, 11(1), e0146193.
- Wilkinson, L., & Friendly, M. (2009). The history of the cluster heat map. *The American Statistician*, 63(2), 179–184.
- Zhang, S., Li, Y., Zhang, S., Shahabi, F., Xia, S., Dou, Y., & Alshurafa, N. (2024). CLEAR: Contrastive learning for multimodal human activity recognition. *npj Digital Medicine*, 7, 112.

